

TP 9-(10-11): Conception et implémentation d'un algorithme d'analyse de sentiment basé sur les aspects

Le terme "analyse des sentiments" est utilisé pour désigner la tâche consistant à déterminer automatiquement la polarité d'un texte, qu'il soit *positif*, *négatif* ou *neutre*. L'analyse de sentiment est de plus en plus considérée comme une tâche essentielle, tant d'un point de vue académique que commercial. La majorité des approches actuelles, cependant, tentent de détecter la polarité globale d'une phrase, d'un paragraphe ou d'un ensemble de mots, indépendamment des entités mentionnées (par exemple, les ordinateurs portables, les restaurants) et de leurs aspects (par exemple, la batterie, l'écran ; la nourriture, le service). Le sentiment peut être déterminé à différents niveaux : le sentiment associé aux mots; le sentiment associé aux phrases, aux SMS, aux messages dans les chats et aux tweets ; au sentiment dans des revues de produits, des articles de blog et des documents entiers.

Le but des TPs 9-10-11 est de concevoir et implémenter un algorithme de classification de sentiment basé sur les aspects. Plus en détail, ces TDPs visent à identifier les aspects des entités cibles données et le sentiment exprimé à l'égard de chaque aspect. Des ensembles de données comprenant des commentaires de clients avec des annotations par des annotateurs humains identifiant les aspects, les entités cibles et la polarité du sentiment de chaque aspect sont fournis.

Les données annotées :

Les phrases des deux jeux de données sont fournies en format XML.

1. Le jeu de données *Restaurant_Train_v0.2* est composé de 3041 phrases en anglais tirées des critiques de restaurants [Ganu et al. (2009)]. Le jeu de données pour inclut des annotations pour les termes d'aspects apparaissant dans les phrases, les polarités des termes d'aspects et les polarités spécifiques aux catégories d'aspects. Des annotateurs humains expérimentés ont identifié les termes d'aspect des phrases et leurs polarités.

L'exemple suivant illustre le format des phrases annotées du jeu de données sur les restaurants.

```
<sentence id="813">
  <text>All the appetizers and salads were fabulous, the steak was mouth watering
and the pasta was delicious!!!</text>
  <aspectTerms>
    <aspectTerm term="appetizers" polarity="positive" from="8" to="18"/>
    <aspectTerm term="salads" polarity="positive" from="23" to="29"/>
```

```

    <aspectTerm term="steak" polarity="positive" from="49" to="54"/>
    <aspectTerm term="pasta" polarity="positive" from="82" to="87"/>
  </aspectTerms>
  <aspectCategories>
    <aspectCategory category="food" polarity="positive"/>
  </aspectCategories>
</sentence>

```

Les valeurs possibles pour la polarité des aspects sont : “positive”, “negative”, “conflict”, “neutral”. Les valeurs possibles des categories sont : “food”, “service”, “price”, “ambiance”, “anecdotes/miscellaneous”.

Note: les données sont annotées aussi par rapport a la polarité “conflictuelle”, c’est-à-dire à la fois positive et négative, mais nous ne prendrons pas en compte cette polarité. On se concentrera sur la polarité positive, négative ou neutre.

2. Le jeu de données *Laptop_Train_v0.2* est composé de 3045 phrases anglaises extraites des commentaires des clients sur les ordinateurs portables. Des annotateurs humains expérimentés ont annoté les termes d'aspect des phrases et leurs polarités.

L'exemple suivant illustre le format des phrases annotées du jeu de données sur les ordinateurs portables (pour ce jeu de données il n’y a pas d’annotation des categories).

```

<sentence id="353">
  <text>From the build quality to the performance, everything about it has been sub-
  par from what I would have expected from Apple.</text>
  <aspectTerms>
    <aspectTerm term="build quality" polarity="negative" from="9" to="22"/>
    <aspectTerm term="performance" polarity="negative" from="30" to="41"/>
  </aspectTerms>
</sentence>

```

Veuillez noter que :

- Toute citation dans un terme d'aspect (par exemple, “sales” team) a été remplacée par “ ; (le texte et les offsets restent les mêmes), par exemple, <aspectTerm term=""sales"team" .../>.
- Les phrases peuvent contenir des fautes d'orthographe.
- Pour chaque terme d'aspect des données de entrainement, nous incluons deux attributs ("de" et "à") qui indiquent son décalage de début et de fin dans le texte (par exemple, <aspectTerm term="staff" polarity="negative" from="8" to="13"/>).

Pour la premiere tache, nous ne prenons pas en compte les categories.

Tache : Determiner la polarité des termes des aspects

En partant des deux jeux de données annotées avec les termes des aspects et leur polarité, il faut concevoir un algorithme capable de déterminer automatiquement si la polarité de chaque terme d'aspect est *positive*, *négative* ou *neutre*.

Exemple :

"I loved their **fajitas**" → {*fajitas: positive*}

"I hated their **fajitas**, but their **salads** were great" → {*fajitas: negative, salads: positive*}

"The **fajitas** are their first plate" → {*fajitas: neutral*}

On commence par télécharger les fichiers suivants qui se trouvent dans le repertoire TP9 sur Moodle :

- Restaurants_Train.xml
- Laptops_Train.xml
- Restaurants_Test_Gold.xml
- Laptops_Test_Gold.xml
- Restaurants_Test_NoLabels.xml
- Laptops_Test_NoLabels.xml

Les deux fichiers *Restaurants_Train.xml* et *Laptops_Train.xml* sont a utiliser pour la phase d'entrainement.

Les fichiers *Restaurants_Test_NoLabels.xml* et *Laptops_Test_NoLabels.xml* sont a utiliser pour tester votre algorithme.

Par exemple :

```
<text>All the appetizers and salads were fabulous, the steak was mouth watering and the
pasta was delicious!!!</text>
<aspectTerms>
<aspectTerm term="appetizers" polarity="" from="8" to="18"/>
<aspectTerm term="salads" polarity="" from="23" to="29"/>
<aspectTerm term="steak" polarity="" from="49" to="54"/>
<aspectTerm term="pasta" polarity="" from="82" to="87"/>
</aspectTerms>
```

Les annotations produites par votre algorithme sont a comparer avec celles contenues dans les fichiers *Restaurants_Test_Gold.xml* et *Laptops_Test_Gold.xml*.

Par exemple :

```
<text>All the appetizers and salads were fabulous, the steak was mouth watering and the
pasta was delicious!!!</text>
<aspectTerms>
<aspectTerm term="appetizers" polarity="positive" from="8" to="18"/>
<aspectTerm term="salads" polarity="positive" from="23" to="29"/>
<aspectTerm term="steak" polarity="positive" from="49" to="54"/>
```

```
<aspectTerm term="pasta" polarity="positive" from="82" to="87"/>
</aspectTerms>
```

Pour implementer votre algorithme d'analyse de sentiment basée sur les aspects vous pouvez prendre en compte les elements suivants :

1. Pré-traitement des phases (negation, tokenizer, PoS tagger, et NER):
 - NLTK
<https://www.nltk.org/book/ch03.html#chap-words>
<https://www.nltk.org/book/ch05.html#chap-tag h>
<https://www.nltk.org/book/ch07.html>
2. Comme le but de votre algorithme n'est pas de classifier la phrase (par exemple "All the appetizers and salads were fabulous, the steak was mouth watering and the pasta was delicious!!!"), mais de determiner le sentiment relatif aux aspects identifiés dans la phrase (par exemple, "appetizers", "salads", "steak"), une stratégie possible consiste a chercher dans la phrase l'aspect donné en entrée et prendre en compte les mots qui entourent cet aspect (dans une fenêtre $t-n$ et $t+n$ ou t est la position du mot relatif a l'aspect sur lequel on se focalise). Il y a différents façons de choisir n , par exemple d'une façon empirique (en se basant sur les données du gold standard) ou en résultat d'une parsification de la phrase.
3. Determiner la polarité des termes en utilisant des ressources lexicales comme les suivantes :
 1. SentiWordNet (<https://github.com/aesuli/SentiWordNet>)
 2. Sentiment Lexicon (<https://www.kaggle.com/rtatman/sentiment-lexicons-for-81-languages>)
4. Deux solutions sont possibles pour calculer le sentiment des aspects en entrée :
 1. Approche a règles : un stratège de base (baseline) consiste a sommer les polarités des mots dans la phrases en utilisant les ressources lexicales dédiées a cette tache (voir point 3) et normaliser cette somme. Un approche a règles vise a améliorer cette strategie de base avec des règles qui sont déterminées explicitement pour les revues contenues dans les deux jeux de données.
 2. Apprentissage automatique: vous pouvez utiliser ces ressources lexicales avec les elements relevant de la structure syntaxique de la phrase (negation, tokenisation) comme *features* pour classifier les termes avec leur polarité : positive, negative, neutral. Vous pouvez utiliser la suite scikit-learn (<https://scikit-learn.org/stable/index.html>) pour effectuer cette tache de classification.
5. Evaluation de vos résultats :

$$\text{précision}_i = \frac{\text{nb de documents correctement attribués à la classe } i}{\text{nb de documents attribués à la classe } i}$$

$$\text{rappel}_i = \frac{\text{nb de documents correctement attribués à la classe } i}{\text{nb de documents appartenant à la classe } i}$$

$$F = 2 \cdot \frac{(\text{précision} \cdot \text{rappel})}{(\text{précision} + \text{rappel})}$$